

Caracterizando a Atividade de Code Review no GitHub





Sistema

O presente sistema coleta dados de repositórios GitHub e analisa os code reviews, assim como os dados das merges presentes.



Hipóteses

- **RQ01:** Qual a relação entre o tamanho dos PRs e o feedback final das revisões?
 - Hipótese: Espera-se que PRs menores tenham maior chance de serem merged, pois são mais fáceis de revisar.
- **RQ02:** Qual a relação entre o tempo de análise dos PRs e o feedback final das revisões?
 - Hipótese: Espera-se que PRs com tempo de análise menor tenham maior chance de serem merged.



Hipóteses

- **RQ03:** Qual a relação entre a descrição dos PRs e o feedback final das revisões?
 - Hipótese: Espera-se que PRs com descrições mais detalhadas tenham maior chance de serem merged.
- **RQ04:** Qual a relação entre as interações nos PRs e o feedback final das revisões?
 - Hipótese: Espera-se que PRs com mais interações tenham maior chance de serem merged.



Hipóteses

- **RQ05:** Qual a relação entre o tamanho dos PRs e o número de revisões realizadas?
 - Hipótese: Espera-se que PRs maiores requerem mais revisões.
- **RQ06:** Qual a relação entre o tempo de análise dos PRs e o número de revisões realizadas?
 - Hipótese: Espera-se que PRs com mais tempo de análise tenham mais revisões.



Hipóteses

- **RQ07:** Qual a relação entre a descrição dos PRs e o número de revisões realizadas?
 - Hipótese: Espera-se que PRs com descrições mais detalhadas tenham menos revisões.
- **RQ08:** Qual a relação entre as interações nos PRs e o número de revisões realizadas?
 - Hipótese: Espera-se que PRs com mais interações tenham mais revisões.



Discussão das hipóteses

RQ1: É possível que PRs maiores tenham conteúdo de maior importância, levando à maior taxa de merge



Dados coletados

- Tamanho: número de arquivos alterados + total de linhas adicionadas e removidas
- Tempo de Análise: intervalo entre a criação do PR e a última atividade (fechamento ou merge)
- Descrição: número de caracteres do corpo de descrição do PR



Dados coletados

- Interações: número de participantes + número de comentários
- Status do PR: binário (MERGED = 1, CLOSED = 0)
- Número de Revisões: total de revisões realizadas



Resultado: Tamanho do PR (Arquivos + Linhas)

- Média: 30.34
- Mediana: 2.08
- Desvio Padrão: 456.27



Resultado: Tempo de análise (horas)

- Média: 924.95
- Mediana: 46.32
- Desvio Padrão: 3814.34



Resultado: Descrição (caracteres)

- Média: 330.65
- Mediana: 330.00
- Desvio Padrão: 117.49



Resultado: Iterações

- Média: 5.70
- Mediana: 4.00
- Desvio Padrão: 12.45



Resultado: Status do PR (Merged=1, Closed=0)

- Média: 0,78
- Mediana: 1
- Desvio padrão: 0.42



Resultado: Número de revisões

- Média: 2.51
- Mediana: 1
- Desvio padrão: 4.01

Distribuição de Status dos Pull Requests

Número de PRs

12000

10000

8000

6000


4000

2000


0

Fechados

Merged




Distribuição de PRs por Tempo de Análise




RQ01: Tamanho do PR vs Status do PR (Merged=1)

$r = -0.065$, $p = 0.000$




RQ02: Tempo de Análise (horas) vs Status do PR (Merged=1)

$r = -0.268$, $p = 0.000$




RQ03: Tamanho da Descrição vs Status do PR (Merged=1)
 $r = 0.052$, $p = 0.000$




RQ04: Total de Interações vs Status do PR (Merged=1)

$r = -0.117$, $p = 0.000$




RQ05: Tamanho do PR vs Número de Revisões

$r = 0.010$, $p = 0.214$




RQ06: Tempo de Análise (horas) vs Número de Revisões

$r = -0.004$, $p = 0.596$




RQ07: Tamanho da Descrição vs Número de Revisões

$r = 0.032$, $p = 0.000$



RQ08: Total de Interações vs Número de Revisões

$r = 0.268$, $p = 0.000$





Correlação entre Métricas de PR

